Réseau de Hopfield, modèle de mémoire associative

La *cybernétique*, qui se développe dans les années 1940, regroupe de multiples disciplines dans le but d'édifier une science du fonctionnement de l'esprit. Cette ambition passe par la modélisation de facultés telles que l'apprentissage, le traitement de l'information perceptive, la mémorisation.

La cybernétique s'inspire très tôt des progrès en neurosciences. En 1982, Hopfield propose un *réseau de neurones artificiels* capable de *mémoire associative* : à partir d'un stimulus initial, le réseau peut retrouver certaines configurations, assimilables à des *souvenirs*.

Ce projet informatique vise à implémenter le réseau de Hopfield et à étudier certaines de ses propriétés.

1 Formalisme et représentation du réseau de Hopfield

1.1 Du neurone biologique au neurone artifciel

L'unité élémentaire du réseau de Hopfield est le *neurone artificiel*. Il s'agit d'un *modèle* mathématique de neurone biologique, conçu pour en imiter les propriétés de *traitement des informations* et de *communication*.[1]
Cette partie présente l'analogie entre neurone biologique et neurone artificiel pour comprendre l'origine de ce concept.

Neurone biologique
Un neurone biologique est une cellule constituée de plusieurs éléments fonctionnels :

- Les *dendrites* sont des 'branches' par lesquelles le neurone *reçoit* les signaux issus d'autres neurones du réseau, sous la forme de courants électriques.
- Le *corps cellulaire* est la partie centrale du neurone, qui détermine sa réaction aux stimulations. A ce niveau, les courants électriques reçus s'additionnent, ce qui module la valeur du potentiel électrique du neurone. Si ce potentiel franchit un *seuil d'activation*, alors le neurone émet une décharge électrique appelée *potentiel d'action*.
- L'*axone* est une 'branche' par laquelle le potentiel d'action est *transmis* aux autres neurones du réseau.

Au niveau des dendrites, la communication entre deux neurones s'opère via une *synapse*. L'efficacité des synapses à transmettre les signaux permettent d'ajuster le fonctionnement du neurone. D'une part, l'efficacité de la synapse entre le neurone i et le neurone j détermine l'influence du signal issu du neurone i dans la réponse du neurone j. D'autre part, une synapse peut être de nature *excitatrice*, si l'information qu'elle transmet a tendance à activer le neurone (courant positif), ou de nature *inhibitrice* dans le cas contraire (courant négatif).

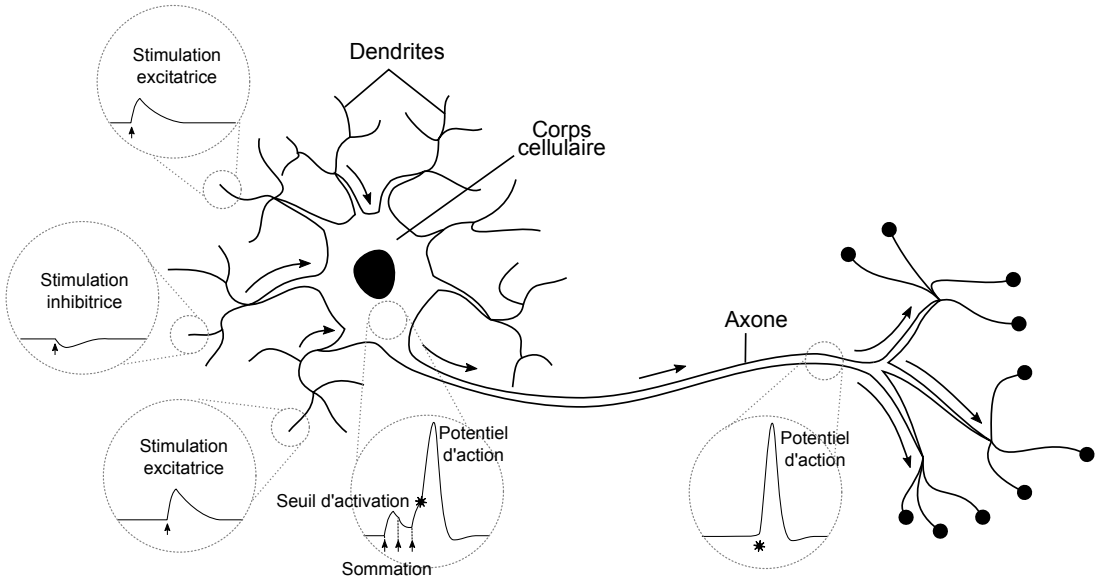


FIGURE 1 – Fonctionnement d'un neurone biologique.
Les stimulations issues d'autres neurones du réseau sont reçues au niveau des dendrites, via des synapses (non détaillées). Ces stimulations, qui peuvent être inhibitrices ou excitatrices, sont sommées au niveau du corps cellulaire. Si la stimulation résultante franchit le seuil d'activation du neurone, celui-ci émet un potentiel d'action. Ce nouveau signal est transmis le long de son axone, et ainsi distribué aux autres neurones du réseau.

1. Le concept de neurone artificiel a été formalisé en 1943 par McCulloch et Pitts, s'inspirant des cellules rétiniennes de grenouille.

Neurone artificiel

Chaque neurone est caractéristée par son *état d'activation*. Pour simplifier, l'état d'un neurone vaut 1 lorsqu'il émet un potentiel d'action, et -1 lorsqu'il est silencieux. [2]
L'état d'un neurone est donc une variable binaire :

$$X_i \in \{-1, 1\} \; \forall \, i \in \{1, 2, ..., N\}.$$

avec N le nombre de neurones dans le réseau, et i le neurone considéré.
Les différents éléments fonctionnels du neurone biologique sont modélisés de la manière suivante :

- Les dendrites correpondent aux *variables d'entrées* reçues par le neurone i, qui sont les états des autres neurones du réseau :
  $\{X_j, \; j \in \{1, 2, ..., N\}, \; j \neq i\}$.
- L'efficacité des synapses est reflétée par des coefficients appelés *poids*, supposés fixés pour l'instant. Ceux-ci peuvent être positifs (synapse excitatrice) ou négatifs (synapse inhibitrice). On note W_{ji} le poids du neurone j vers le neurone i.
- Le corps cellulaire est modélisé par la réalisation de deux calculs :
  (1) La *somme* des entrées *pondérées* par les poids : $\sum_{j=1}^{N} W_{ij} X_j(t)$
  (2) La *fonction d'activation*, qui compare la somme pondérée des entrées à un *seuil* (choisi nul ici) :
  $F(x) = \begin{cases} -1 & \text{si} \quad x < 0 \\ 1 & \text{si} \quad x \geq 0 \end{cases}$
  Il s'agit d'une fonction en escalier, passant de -1 à 1 en 0.
- L'axone correspond à la *variable de sortie*, qui est la valeur renvoyée par la fonction d'activation. C'est cette valeur, -1 ou $+1$, qui donne alors l'état du neurone.

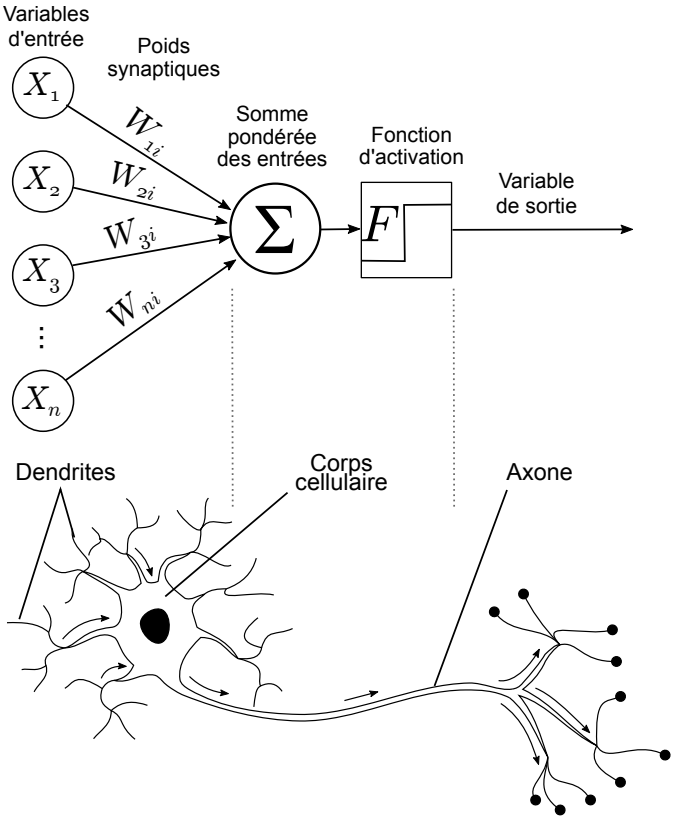


FIGURE 2 – Analogie entre neurone biologique et neurone artificiel.
Le neurone i correspond à une variable X_i. Il reçoit en entrée les états d'activation $X_j, \; j \neq i$ de tous les autres neurones. Le neurone i effectue la somme de ces variables d'entrée, pondérée par les poids W_{ji} qui le relient aux autres neurones. Cette somme résultante, si elle est supérieure à 0, conduit le neurone i à s'activer ($X_i = +1$), et le conduit à s'inactiver sinon ($X_i = -1$). La nouvelle valeur de X_i est ensuite envoyée aux autres neurones en sortie.

1.2 Du neurone individuel au réseau

Le traitement de l'information par chaque neurone montre que celle-ci n'est pas contenue dans les neurones individuels, qui ne peuvent prendre que deux valeurs. C'est plutôt le *comportement global* du réseau qui permet de représenter *collectivement* l'information, et d'effectuer des traitements plus complexes. [3]

Pour représenter l'*état global* du réseau constitué de N neurones, on peut utiliser un *vecteur* de N composantes, chacune indiquant l'état d'activation d'un neurone individuel :

$$X := \begin{pmatrix} X_1 \\ \vdots \\ X_N \end{pmatrix}$$

L'ensemble des états possibles du réseau est donc constitué de toutes les combinaisons des états individuels. [4]

De plus, les poids entre *toutes* les paires de neurones sont spécifiés dans une matrice $W = (W_{ij})$ de dimensions (N, N), où le terme W_{ij} correspond au poids du neurone i vers le neurone j. Cette matrice respecte deux contraintes :

1. Symétrie : $\forall \, i, j, \; W_{ij} = W_{ji}$.
2. Diagonale nulle (pas d'auto-connexion) : $\forall \, i, \; W_{ii} = 0$.

2. Cette hypothèse simplificatrice permet d'obtenir des résultats théoriques intéressants. Il existe toutefois des versions plus élaborées du réseau de Hopfield, dans lesquelles chaque neurone peut prendre des valeurs continues.

3. Les travaux de Mc Culloch et Pitts montrèrent que des réseaux de neurones formels simples peuvent possèder des capacités computationnelles intéressantes, notamment réaliser des fonctions logiques, arithmétiques et symboliques complexes.

4. Dans la suite, le terme 'état' désignera en général l'état global du réseau. Pour faire référence aux états individuels des neurones, on parlera plutôt de valeur ou d'état d'activation.

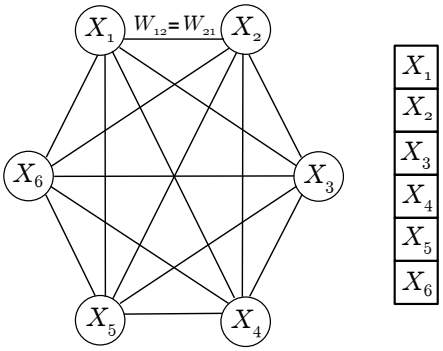


FIGURE 3 – Représentation d'un réseau de Hopfield constitué de $N = 6$ neurones.
A gauche, le réseau est représenté de façon explicite. Chaque variable $X_i,\ i \in \{1, ..., 6\}$ correpond à un neurone. Chaque connexion représente le poids synaptique entre deux neurones.
A gauche, le réseau est représenté sous la forme d'un vecteur. Il est associé à une matrice des poids W, non figurée ici.

1. Pour un réseau de N neurones, combien existe-t-il d'états possibles, sachant que chaque neurone est une variable binaire ?

2. Créer une fonction initialisant un réseau de Hopfield dans un état aléatoire. On pourra affecter aléatoirement à chaque neurone une valeur initiale 1 ou -1. La fonction renverra un `array numpy` de longueur N. Justifier le choix du format de représentation du réseau.
Indication : Initialiser pour commencer un réseau de taille $10 \times 10 = 100$ *neurones.*

3. Créer une fonction construisant une matrice de poids pour un réseau de taille N. Celle-ci devra renvoyer un `array numpy` de dimension (N, N). On pourra choisir des connexions aléatoires entre chaque paire de neurones, par exemple comprises dans l'intervalle $[-1, 1]$.

Dans ce projet, le type d'information que l'on cherchera à représenter en général est un ensemble d'images. On pourra alors supposer que les neurones sont agencés spatialement sur une grille carrée.
On s'intéressera donc à des réseaux dont le nombre de neurones N est un carré parfait, ce qui permettra de visualiser le réseau en affichant les N composantes du vecteur dans un carré de côté $\sqrt{N}$ pixels. [5]

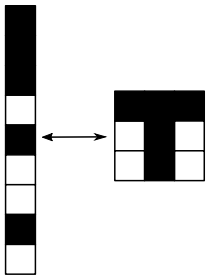


FIGURE 4 – Représentation d'un réseau de Hopfield constitué de $N = 9$ neurones.
Chaque neurone est représenté par un pixel. Une case noire correspond à l'état 1 et une case blanche à l'état -1.

1. Créer une fonction convertissant un vecteur de longueur N en une matrice carrée de dimensions $(\sqrt{N}, \sqrt{N})$.

2. Créer une fonction affichant l'image représentée par un réseau dans une configuration donnée.
Indication : On pourra utiliser la fonction `imshow` *pour représenter graphiquement les valeurs de la matrice.*

5. Attention : la matrice des poids W n'a aucun lien avec l'image représentée par le réseau.

2 Dynamique du réseau de Hopfield et Mémoire associative

2.1 Equation d'évolution

Le réseau de Hopfield est un système dynamique : tout comme les réseaux de neurones biologiques, il *évolue* spontanément au cours du temps. L'évolution du réseau décrit la *succession des états* dans lesquels il se trouve au cours du temps. L'évolution est donc formalisée par une suite vectorielle $(X(t))_t$.

Plus précisément, le passage d'un état du réseau à un autre à chaque itération de temps repose sur la modification des états d'activation des neurones individuels qui le constituent. Pour calculer l'évolution du réseau global au cours du temps, on emploie un mode d'itération *séquentiel aléatoire* : à chaque instant, un seul neurone, choisi aléatoirement, est mis à jour. Ce choix est justifié par l'idée qu'il n'existe pas dans le cerveau d'horloge interne qui synchroniserait les transitions d'état des neurones.

Le réseau de Hopfield est *récurrent* : son état au temps $t+1$ ne dépend que de son état au temps t et des poids entre neurones. Selon la partie 1.1, l'évolution de l'état d'un neurone i est déterminée par l'ensemble des stimulations reçues des autres neurones, dont la somme pondérée est comparée au seuil d'activation (égal à 0).
La mise à jour d'un neurone i se traduit donc par la formule suivante :

$$X_i(t+1) = F\left(\sum_{j=1}^{N} W_{ij} X_j(t)\right)$$

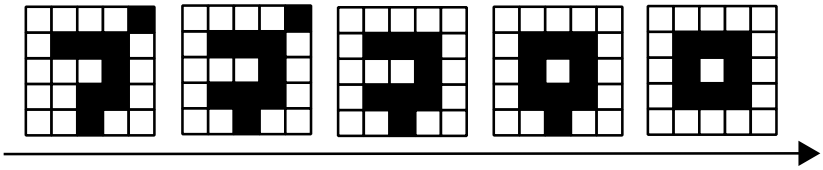


FIGURE 5 – Evolution d'un réseau.
A chaque itération, un neurone est tiré au sort. Sa nouvelle valeur est calculée en fonction des stimulations qu'il reçoit des autres neurones du réseau dans l'état global actuel.

1. Créer une fonction admettant en argument l'état du réseau à un temps donné et calculant le nouvel état d'un neurone i en implémentant l'équation d'évolution.
Indication : On pourra utiliser le produit matriciel.

2. Créer une fonction calculant l'évolution du réseau global sur une itération temporelle.

2.2 Mémoire associative et points fixes attracteurs

Le réseau de Hopfield a été initialement conçu pour modéliser le phénomène de *mémoire associative*. Comment modéliser cette fonction cognitive avec un réseau de neurones binaires ?

En psychologie, la remémoration désigne le processus qui permet de ramener à la conscience des *souvenirs*. Ce processus opère donc une *réactivation* ou une *reconstruction* d'une représentation mentale préalablement apprise ou enregistrée. La remémoration est initiée par une *information partielle*, qui *évoque* un souvenir particulier. Par exemple, apercevoir une partie du visage de la Joconde mène à reconstituer l'image mentale du tableau entier.

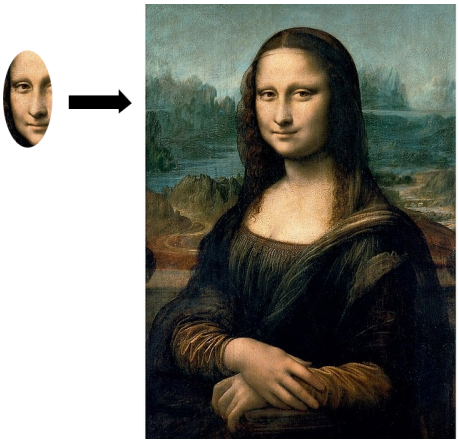


FIGURE 6

En termes de réseau, un souvenir peut alors être défini comme un *état* vers lequel le réseau *évolue spontanément*, et dans lequel il se *maintient* une fois qu'il l'a atteint. Plus précisément, ceci requiert que, partant d'un état initial, le réseau *converge* vers un état *stable*. L'état initial fourni au réseau s'interprète alors comme l'*information partielle* évoquant le souvenir.

Cette conception de la mémoire associative en termes de réseau mène à définir formellement plusieurs notions :

Points fixes attracteurs

Le terme *point fixe attracteur* qualifie un état du réseau qui possède les propriétés requises pour être un souvenir :

— *Equilibre* : un *point fixe* de l'*équation d'évolution* est défini comme un vecteur X de l'espace des états vérifiant :

$$\forall i \in \{1, ..., N\},\ F\left(\sum_{j=1}^{N} W_{ij} X_j\right) = X_i$$

Autrement dit, il s'agit d'un état du réseau dans lequel les stimulations mutuelles entre neurones conduisent tous les neurones à conserver leur valeur.

— *Convergence et stabilité* : un *attracteur* du réseau est défini comme un vecteur X de l'espace des états vers lequel converge la suite vectorielle $(X(t))_t$. Rappel : cette suite correspond à l'évolution du réseau au cours du temps.

Bassin d'attraction

Pour un réseau avec ses paramètres W fixés, il peut exister différents points fixes attracteurs, qui sont les différentes limites possibles de la suite $(X(t))_t$. C'est l'*état intial* qui détermine lequel est atteint au terme de l'évolution du réseau.

Le *bassin d'attraction* d'un point fixe attracteur est constitué par l'ensemble des états initiaux menant à celui-ci. Si le réseau possède plusieurs points fixes attracteurs, chacun possède un bassin d'attracteur distinct. Les bassins attracteurs des différents points fixes sont nécessairement disjoints.

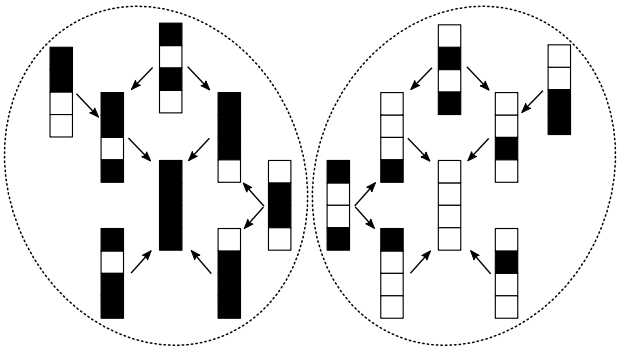


FIGURE 7 – Points fixes attracteurs et bassins d'attraction pour un réseau constitué de $N = 4$ neurones.
Comme précédemment, chaque état est représenté par une colonne, dans laquelle chaque pixel correspond à un neurone (noir : 1, blanc : -1). Les évolutions possibles entre ces états sont figurées par les flèches. Les deux points fixes attracteurs sont les états totalement noirs et totalement blancs, vers lesquels converge le réseau quel que soit l'état initial. Leurs bassins d'attraction, encerclés en pointillés, comprennent tous les états initiaux menant vers ces deux points fixes attracteurs.

1. Créer une fonction calculant l'évolution d'un réseau sur un nombre d'itérations T. Indentifier un point fixe attracteur si le réseau en atteint un.
Indication : ceci signifie qu'à un certain moment, le réseau cesse d'évoluer.

2. Vérifier que différents états initiaux peuvent conduire au même point fixe attracteur. On a alors trouvé plusieurs éléments de son bassin d'attraction.

2.3 Energie du système

Existe-t-il des propriétés supplémentaires qui caractérisent les points fixes attracteurs parmi les états du réseau ?

Intuitivement, on peut attendre d'un état stable du réseau qu'il reflète les relations de coopération et de compétition entre les neurones. Dans un tel état, les neurones reliés par des poids positifs, 'coopératifs', devraient être actifs simultanément, tandis que les neurones reliés par des poids négatifs, 'compétiteurs', devraient se trouver dans des états d'activation opposés.

La stabilité des états peut être quantifiée en introduisant une grandeur *énergie*, par analogie avec la physique. L'énergie est une fonction définie sur l'ensemble des états du réseau, associant à chaque état un réel reflétant sa

'capacité à changer'. Ainsi, plus un état est stable, plus son énergie est faible. Dans le cas du réseau de Hopfield, l'énergie d'un état peut être définie par la formule suivante :[6]

$$E(t) = -\frac{1}{2}\sum_{i}^{N}\sum_{j}^{N} W_{ij}X_j(t)X_i(t)$$

L'interprétation de cette formule coïncide avec l'intuition :

— Si dans l'état du réseau considéré, deux neurones se trouvent dans le même état d'activation ($X_iX_j > 0$) et sont reliés par des poids positifs ($W_{ij} > 0$), alors la paire contribue à réduire l'énergie totale (via le signe -1), ce qui rend l'état du réseau plus stable.

— A l'inverse, si deux neurones se trouvent dans le même état d'activation mais sont reliés par des poids négatifs ($W_{ij} < 0$), alors l'activité de la paire accroît l'énergie totale, ce qui rend l'état du réseau moins stable.

L'énergie permet ainsi de dégager une propriété supplémentaire des points fixes attracteurs : ils doivent correspondent aux *minima* d'énergie.

La notion d'énergie permet également d'aller plus loin dans l'analyse de l'évolution du réseau. En effet, l'énergie est une fonction monotone décroissante lors de l'évolution du réseau (la démonstration est proposée en exercice ci-dessous). Ceci signifie que, quel que soit l'état initial, le réseau évolue toujours vers des états d'*énergie décroissante*, jusqu'à rencontrer un point fixe attracteur.

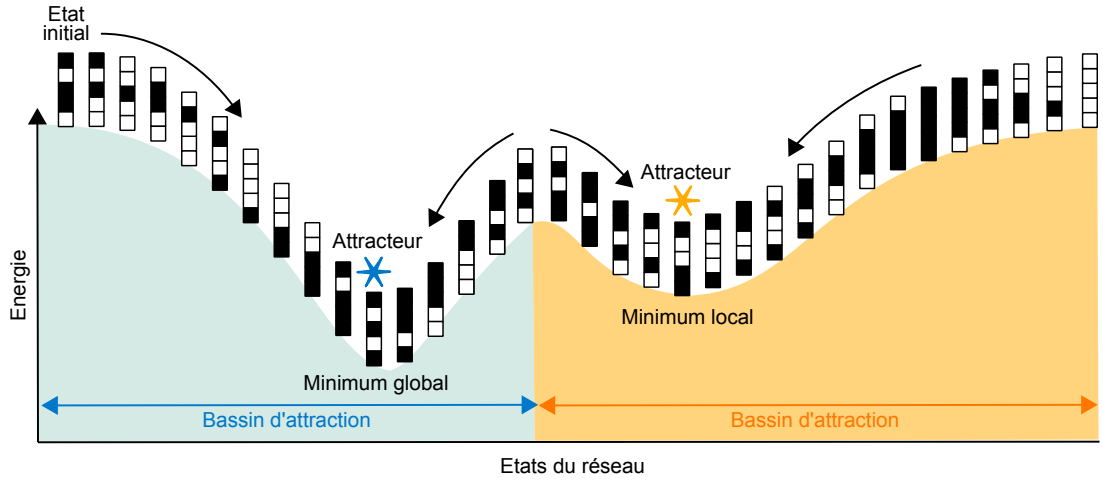


FIGURE 8 – Paysage énergétique d'un réseau de $N = 5$ neurones.
A chaque état du réseau est associée une énergie. Les points fixes attracteurs sont associés aux minima d'énergie. Si le réseau est placé dans un état initial, son énergie va décroître spontanément jusqu'à converger vers un attracteur. L'attracteur atteint dépend de la position de l'état initial parmi les bassins d'attraction des différents attracteurs.

1. Créer une fonction calculant l'énergie d'un état du réseau fourni en argument.

2. Simuler l'évolution d'un réseau de Hopfield tout en sauvegardant les valeurs d'énergie des différents états rencontrés.
Représenter graphiquement l'évolution de l'énergie au cours du temps.
Vérifier que l'énergie est bien décroissante au cours de l'évolution du réseau.

3. Prouver analytiquement les propriétés de l'énergie :
   — Justifier que l'énergie admet une borne inférieure.
   — Exprimer $E(t+1)$ en fonction de $E(t)$, en considérant qu'un seul neurone a vu son état modifié. En étudiant le signe de $\Delta E = E(t+1) - E(t)$, prouver que l'énergie décroît entre chaque itération.
   — En déduire que la suite $(E(t))_t$ est stationnaire (à partir d'un certain rang). Conclure sur l'existence de points fixes.

6. Cette formule est analogue du modèle de Ising en physique statistique, pour les matériaux ferromagétiques.

3 Apprentissage et Remémoration

Sachant que le réseau de Hopfield est capable de remémorer des souvenirs, on peut se poser la question suivante : pourrait-on construire un réseau dont les points fixes attracteurs soient des souvenirs choisis *arbitrairement* ? Dans la suite, ces états seront appelés *références*.

3.1 Apprentissage et optimisation des poids

Comme le montre la formule de l'énergie, la stabilité des états ne dépend que de la matrice des poids. Ce sont donc les poids synaptiques qui contiennent toute l'information permettant de retrouver les souvenirs. Pour que les souvenirs du réseau correspondent bien aux références choisies arbitrairement, il suffit donc de trouver les valeurs appropriées de ces paramètres.

L'*apprentissage* désigne la phase d'optimisation des poids synaptiques dans le but d'accomplir une tâche (ici, la remémoration des références). On suppose que cette étape est effectuée avant les périodes de remémoration qui ont été étudiées jusqu'à présent.

L'apprentissage consiste à 'présenter' successivement les références au réseau. Chaque présentation consiste à placer le réseau dans l'état correspondant à la référence, et à appliquer une *règle d'apprentissage* pour modifier les poids synaptiques.

Placer le réseau dans un état arbitraire peut être inteprété comme l'effet d'une *stimulation externe*, par opposition à l'évolution spontanée du réseau traitée jusqu'à présent, qui dépendait uniquement de son état actuel.

Plusieurs règles d'apprentissage ont été proposées pour le réseau de Hopfield, se révélant de différentes efficacités pour la remémoration des souvenirs.

3.2 Règle d'apprentissage de Hebb

En biologie, le *postulat de Hebb* suggère que l'apprentissage fait intervenir le renforcement des synapses entre neurones dont l'activité est corrélée, et inversement la dégénérescence de celles dont l'activité est décorrélée. Autrement dit, l'activation simultanée de deux neurones accroît l'efficacité de leur communication, tandis que leur activation désynchronisée réduit encore leur coopérativité.

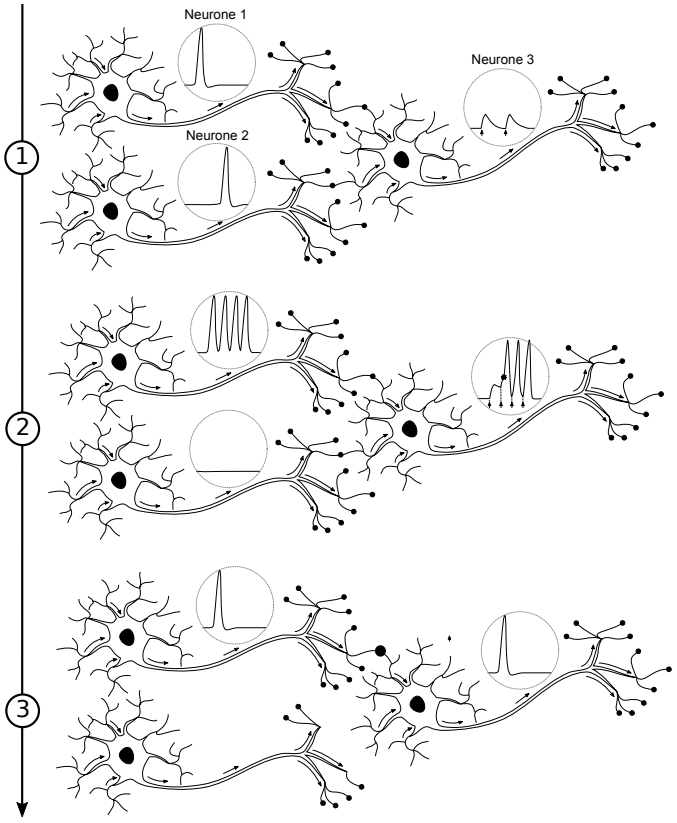


FIGURE 9 – Postulat de Hebb en biologie.
(1) Lorsque le neurone 1 s'active, la connexion synaptique qu'il entretient avec le neurone 3 n'est pas suffisante pour que le neurone 3 s'active aussi en émettant un potentiel d'action. De même entre les neurones 2 et 3.
(2) Le neurone 1 envoie au neurone 3 une stimulation intense, qui parvient à déclencher l'activation du neurone 3. Ainsi, les deux neurones sont synchronisés sur trois potentiels d'action. A l'inverse, les neurones 2 et 3 sont alors complètement désynchronisés, puisque le neurone 2 n'est pas actif durant cette période.
(3) L'événement précédent a renforcé l'efficacité de la synapse entre les neurones 1 et 3 : désormais, lorsque le neurone 1 s'active, la connexion avec le neurone 3 est suffisante pour que le neurone 3 réponde en émettant un potentiel d'action. A l'inverse, la synapse entre les neurones 2 et 3 a dégénéré.

Le postulat de Hebb peut être implémenté pour le réseau de Hopfield. Lors de l'apprentissage, à chaque présentation d'une référence, la matrice W est modifiée selon la règle suivante :

— si deux neurones i et j sont dans le même état d'activité dans la référrence actuelle (tous deux $+1$ ou tous deux -1), alors le coefficient W_{ij} est incrémenté de $+1$,

— si deux neurones i et j sont dans des états d'activité opposés (l'un $+1$ et l'autre -1), alors le coefficient W_{ij} est décrémenté de -1.

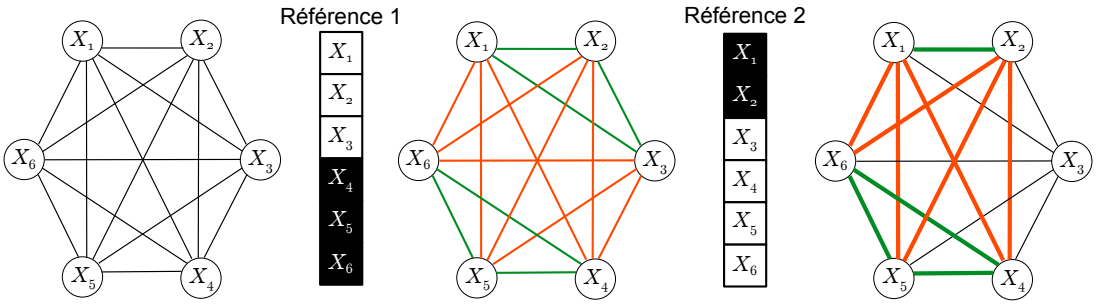


FIGURE 10 – Application de la règle de Hebb pour un réseau de $N = 6$ neurones, lors d'un apprentissage de $m = 2$ références. Les poids sont représentés par les segments joignant les neurones. La couleur symbolise le signe du poids : vert pour un poids positif, orange pour un poids négatif, noir pour un poids nul. L'épaisseur symbolise la magnitude du poids (sauf pour les segments noirs) : trait fin pour ± 1, trait épais pour ± 2.
Initialement, tous les poids sont nuls par défaut.
Lors de la présentation de la première référence, les neurones se répartissent en deux groupes d'activation opposés : les neurones 1, 2 et 3 s'activent ensemble, les neurones 4, 5 et 6 s'inactivent ensemble. Ceci conduit au renforcement des poids entre les neurones $1, 2, 3$ d'une part, et entre les neurones $4, 5, 6$ d'autre part. Au contraire, les poids entre les neurones appartenant à des groupes opposés deviennent négatifs.
Lors de la présentation de la seconde référence, les neurones 1 et 2 s'inactivent ensemble, ce qui renforce encore davantage leur connexion (même s'ils sont inactifs, ils sont synchronisés). Les neurones 4, 5 et 6 s'activent ensemble, ce qui renforce aussi leur connexion. Le neurone 3 s'active avec le groupe de neurones 4, 5 et 6, ce qui abolit le signe négatif des poids entre eux. De même, comme le neurone 3 n'est plus dans le même état d'activation que les neurones 1 et 2, donc la connexion positive entre eux est effacée.

Au terme de la période d'apprentissage, les poids synaptiques obtenus sont donc donnés par la formule suivante :

$$W_{ij} = \sum_{s=1}^{m} X_i^{(s)} . X_j^{(s)}$$

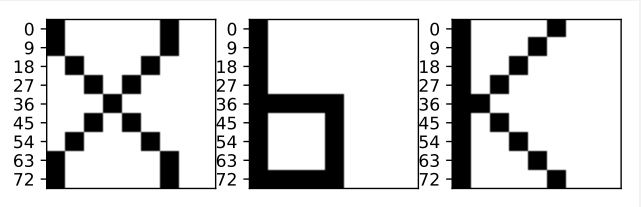
avec m le nombre de références, et $X^{(s)}$ la s^{eme} référence.

On constate que dans le cas de la règle de Hebb, on dispose d'une formule explicite permettant de calculer directement la matrice W optimale pour que les souvenirs du réseau correspondent aux références (si celles-ci sont fixées à l'avance). Ainsi, il n'est pas nécessaire de simuler véritablement la période d'apprentissage. On peut simplement imaginer qu'elle a eu lieu en amont, avant la création du réseau et la période de remémoration, et définir la matrice W selon la formule précédente. [7]

7. Selon les stratégies d'apprentissage, on ne dispose pas toujours d'une formule explicite, et il faut alors implémenter la période d'apprentissage par des simulations.

1. Créer une fonction admettant en argument un ensemble de références et construisant la matrice W selon la règle de Hebb.

2. Générer une matrice de poids de sorte que les souvenirs soient les références ci-dessous :



3. Vérifier que les références sont bien des souvenirs du réseau.
Pour cela, utiliser des états initiaux 'proches' des références, en modifiant les états de quelques neurones. Ceci correspond à l'idée qu'une information 'partielle' doit permettre au réseau de retrouver la référence complète.
Dans chaque cas, afficher l'état initial et l'attracteur atteint lorsque le réseau n'évolue plus. Vérifier que l'attracteur est bien la référence attendue. [a]

a. Parfois, une légère différence entre l'attracteur observé et la référence est due à la dissymétrie introduite dans la définition de la fonction d'activation pour le cas d'un argument nul.

3.3 Souvenirs parasites

Les simulations précédentes ont permis de vérifier que le bassin d'attraction d'une référence regroupe des états *proches* de celle-ci, la proximité entre deux états du réseau correspondant au nombre de neurones inchangés entre deux états.
Toutefois, on peut se poser les questions suivantes :

— En ayant construit la matrice des poids selon la règle de Hebb, les références sont-elles les *seuls* points fixes attracteurs du réseau ?
— Quel degré d'information partielle doit être contenu dans l'état initial pour qu'une référence soit remémorée ?

En fait, il arrive qu'en partant de certains états initiaux, le réseau aboutisse à des *souvenirs parasites*. Ce sont des points fixes attracteurs différents des références, qui émergent en tant que minima locaux du paysage énergétique.

Un type de souvenirs parasites correspond aux états 'opposés' des références (dans lesquels les valeurs -1 sont remplacées par $+1$ et réciproquement). En effet, deux états opposés possèdent la même énergie. Plus généralement, les souvenirs parasites sont des combinaisons linéaires d'un nombre impair des références utilisées pour construire la matrice W. [8]

Reprendre les trois références du paragraphe précédent. Trouver des états initiaux conduisant à des souvenirs parasites.
Par exemple :

— commencer avec un état initial proche d'un état 'opposé' d'une référence, ou d'un mélange de références,
— montrer qu'une translation n'agit pas comme une petite altération.

8. On peut montrer que si m références ont servi pour construire la matrice des poids synaptiques, au moins $\frac{3^m-(2-1)^m}{2}$ points fixes attracteurs sont générés.